

# 1. 请写出logistic regression的p\_i的解析式

logistic regression的 $p_i$ 是指事件发生的概率， 它可以用以下公式表示：

$$p_i = \frac{1}{1 + e^{-z_i}}$$

其中 $z_i$ 是logit变换后的值， 也就是成功概率和失败概率的比值的自然对数， 它可以用以下公式表示：

$$z_i = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$$

其中 $\beta_0, \beta_1, \cdots, \beta_k$ 是回归系数，  $x_1, x_2, \cdots, x_k$ 是自变量。

# 2. 请结合公式说明为什么logistic regression可以认为是某种形式的线性模型

Logistic regression可以认为是某种形式的线性模型， 因为它的输出变量（即响应事件的概率）的对数几率（logit）是输入变量和参数的线性函数。

也就是说， logistic regression模型可以写成如下形式：

$$\text{logit}(p_i) = \ln\left(\frac{p_i}{1 - p_i}\right) = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \cdots + \beta_p x_{p,i}.$$

其中，  $p_i$ 是第 $i$ 个观测值的响应事件（例如0或1）发生的概率，  $x_{j,i}$ 是第 $i$ 个观测值的第 $j$ 个输入变量，  $\beta_j$ 是第 $j$ 个参数。

这种形式与一般线性模型（generalized linear model）相同， 只不过响应变量经过了一个非线性的转换函数（即对数几率函数）。

# 3. 请从最大似然估计maximum likelihood estimation (MLE)的角度推导出logistic regression的梯度上升的求解方法

logistic regression的梯度上升的求解方法可以从最大似然估计的角度推导出来。具体步骤如下：

假设我们有 $n$ 个样本 $(x_1, y_1), (x_2, y_2), \cdots, (x_n, y_n)$ ， 其中 $y_i$ 是二元分类标签， 取值为0或1。我们假设每个样本的标签服从一个伯努利分布， 即：

$$P(y_i | \mathbf{x}_i, \mathbf{w}) = \hat{p}_i^{y_i} (1 - \hat{p}_i)^{1 - y_i}$$

其中 $\hat{p}_i$ 是logistic regression模型对样本 $\mathbf{x}_i$ 属于类别1的概率预测， 即：

$$\hat{p}_i = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}_i}}$$

其中 $\mathbf{w}$ 是模型参数向量。

那么， 最大似然估计就是要找到一组参数 $\mathbf{w}$ ， 使得所有样本标签出现的联合概率最大化， 即：

$$L(\mathbf{w}) = \prod_{i=1}^n P(y_i | \mathbf{x}_i, \mathbf{w})$$

为了方便计算， 我们通常对上式取对数， 并且加上一个负号变成最小化问题， 即：

$$J(\mathbf{w}) = -\log L(\mathbf{w}) = -\sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]$$

这就是交叉熵损失函数（cross-entropy loss function）。

为了解这个优化问题， 我们可以使用梯度下降法（gradient descent）， 也就是不断地沿着损失函数的负梯度方向更新参数。而梯度上升法（gradient ascent）则是沿着损失函数的正梯度方向更新参数。两者只有符号上的区别。

那么， 我们需要计算损失函数 $J(\mathbf{w})$ 关于参数 $\mathbf{w}$ 的梯度。根据链式法则和导数公式， 我们有：

$$\begin{aligned} \nabla J(\mathbf{w}) &= -\sum_{i=1}^n [y_i(1 - \hat{p}_i) - (1 - y_i)\hat{p}_i] \cdot \nabla\left(\frac{-e^{-\mathbf{x}_i^T \cdot \boldsymbol{\beta}}}{(1 + e^{-\boldsymbol{\beta} \cdot \mathbf{x}_i})^2}\right) \\ &= -(-e^{-x_{ij}\beta_j})(-x_{ij})(-e^{-x_{ij}\beta_j})(-x_{ij})(-e^{-x_{ij}\beta_j})(-x_{ij}) = x_{ij}(y_i - \hat{p}_i) \end{aligned}$$

所以， 使用梯度上升法求解最大似然估计问题时， 每次迭代时需要更新参数为：

$$\boldsymbol{\beta}_{j+1} = \boldsymbol{\beta}_j + \alpha x_{ij}(y_i - \hat{p}_i)$$

其中 $j$ 表示迭代次数，  $\alpha$ 表示学习率。